

Big Data

Segunda Evaluación Parcial

Anexos · Implementación técnica y MVP end-to-end mínimo
Proyecto integrador — Cloud Provider Analytics

Santiago Bolado (64261)	Felipe Zanel Suarez (64914)	Gonzalo Martinez Pagola (64289)	Bautista Manuel Camiño (62075)

Fecha de entrega: 16 de noviembre de 2026

Contenido

	Anexo	Fuente en el repositorio
A	Evidencias de ejecución	`evidence/runs/`, `evidence/idempotencia.md`, `evidence/a07_orden_eventos.md`
B	Muestras de quarantine	`evidence/quarantine_muestras.md`
C	Serving en AstraDB: modelo, CQL, resultados y capturas	`infra/cql/`, `evidence/serving/`
D	Diccionario de datos y trazado de linaje	`docs/diccionario_datos.md`, `evidence/linaje_trazado.md`
E	Backlog final	`docs/backlog_final.md`

Todas las cifras salen de la ejecución en Google Colab del 13/11/2026 (`notebooks/00_pipeline_colab.ipynb`): PySpark 4.2.0, `local[*]`, Java 17. Cada tabla se regenera con el script indicado.

Anexo A · Evidencias de ejecución

A.1 Ingesta batch a Bronze

Una corrida de `batch_to_bronze`, partición `ingest_date` del día. Leídas = Bronze + quarantine en las siete fuentes; si no, el job se detiene.

Fuente	Leídas	Bronze	Quarantine	Archivos	Bytes	s
`customers_orgs`	80	80	0	1	6.849	15,2
`users`	800	800	0	1	23.762	3,7
`resources`	400	400	0	1	11.838	2,9
`support_tickets`	1.000	1.000	0	1	18.983	4,2
`marketing_touches`	1.500	1.500	0	1	23.099	3,0
`nps_surveys`	92	92	0	1	3.741	2,1
`billing_monthly`	240	240	0	1	12.018	2,0

A.2 Orden temporal de los eventos (cierre de A-07)

120 archivos, 43.200 eventos. Cada archivo cubre entre 59,0 y 60,0 días. Correlación entre número de archivo y mediana de su timestamp: -0,0152. `event_id` repetidos: 0. Porcentaje de eventos detrás de un watermark sobre `event_ts`, simulado con un archivo por micro-lote:

Watermark	1 d	2 d	7 d	14 d	30 d	60 d
Descartados	97,5%	95,8%	87,6%	76,0%	49,6%	0,0%
Procesados	2,5%	4,2%	12,4%	24,0%	50,4%	100,0%

A.3 Streaming, Silver, Gold y serving

Job	Resultado
`stream_to_bronze`	120 micro-lotes de 360 · 43.200 filas · 43.200 `event_id` distintos · 0 descartados por watermark · quarantine 0 · 167 s
`silver_job`	43.200 de 43.200 · 360 particiones, 360 archivos · flags: costo_negativo 211, unit_nulo_con_value 2.038, value_nulo 877 · USD 2.968,03 en eventos con métrica nula · 63 s

Job	Resultado
`gold_stream` (flujo C)	120 micro-lotes · 6.392 eventos incorporados · **36.808 tardíos (85,2%)** · latencia por lote: mediana 1282 ms, máx. 12.680 ms · watermark final 2025-08-24
`gold_job` (flujo D)	11.050 filas · grano único · 80 orgs × 60 días × 6 servicios · USD 147.433,98 = Silver · 2.790 filas con `carbon_kg` nulo (solo v1)
`anomalies`	130 anomalías (1,18%): 125 picos, 5 caídas · 54/54 picos inyectados detectados
`load_cassandra` ×2	1.ª: COUNT 0 → 11.050 / 12.314 (67 s) · 2.ª: 11.050 / 12.314 → 11.050 / 12.314 (52 s)

A.4 Rutas, archivos y tamaños

Ruta	Partición	Archivos	Tamaño
`data/bronze/<7 fuentes>/`	`ingest_date`	7	102 KB
`data/bronze/usage_events/`	`ingest_date`	120	3,6 MB
`data/silver/usage_events/`	`event_date`, `service`	360	6,6 MB
`data/silver/customers_orgs/`, `resources/`	—	2	19 KB
`data/gold/org_daily_usage_by_service/`	`usage_date`	60	0,9 MB
`data/gold/org_daily_usage_by_service_speed/`	`batch_id`	120	1,0 MB
`data/gold/cost_anomaly_mart/`	`date`	60	0,9 MB

Lectura. Los eventos ocupan 12,9 MB en JSONL y 3,6 MB en Parquet en Bronze. Silver promedia 18 KB por archivo: a la escala de la muestra el esquema está sobre-particionado, como anticipó D-005. Se mitiga escribiendo un archivo por partición (`repartition` por las columnas de partición) y se justifica contra el escenario dimensionado del TP1, no contra la muestra.

A.5 Idempotencia: dos corridas desde cero

Tabla	Corrida 1	Corrida 2	Detalle (1 / 2)
Bronze customers_orgs	80	80	1 / 1 archivos
Bronze users	800	800	1 / 1 archivos
Bronze resources	400	400	1 / 1 archivos
Bronze support_tickets	1.000	1.000	1 / 1 archivos
Bronze marketing_touches	1.500	1.500	1 / 1 archivos
Bronze nps_surveys	92	92	1 / 1 archivos
Bronze billing_monthly	240	240	1 / 1 archivos
Bronze usage_events (acumulado)	43.200	43.200	micro-lotes procesados: 120 / 0
Silver usage_events	43.200	43.200	360 / 360 archivos
Gold org_daily_usage_by_service	11.050	11.050	USD 147.433,98 / 147.433,98
AstraDB org_daily_usage_by_service (COUNT)	11.050	11.050	2.ª carga: 11.050 filas reenviadas, COUNT 11.050 → 11.050
AstraDB top_services_by_org_14d (COUNT)	12.314	12.314	2.ª carga: 12.314 filas reenviadas, COUNT 12.314 → 12.314

Anexo B · Muestras de quarantine

Generado con `notebooks/03_muestras_quarantine.py`. En Bronze, lo que va a quarantine no entra; en Silver es una copia de auditoría y el evento sigue con su flag (D-009, D-014).

B.1 Silver, dataset real

Regla	Registros	Tratamiento
unit_nulo_con_value	2.038	unidad imputada desde la métrica (D-014)
value_nulo	877	métrica en nulo, el costo promueve (D-009)
costo_negativo	211	flag de negocio, sin copia en quarantine (§8.7)

unit_nulo_con_value · 3 de 2.038 (cómo quedaron en Silver)

event_id	org_id	service	metric	value_raw	unit	cost_usd	quality_flags
evt_003mc7ncrk0z	org_w3zp08j3	genai	requests	120.0	count	11.5385	unit_nulo_con_value
evt_01xb4ljijao2	org_axeqbnhl	compute	cpu_hours	1.7567	hours	0.1357	unit_nulo_con_value
evt_02fpkgce46vv	org_kdgigatj	analytics	cpu_hours	1.1257	hours	0.0927	unit_nulo_con_value

value_nulo · 3 de 877 (cómo quedaron en Silver)

event_id	org_id	service	metric	value_raw	unit	cost_usd	quality_flags
evt_00kblszrjmnm	org_w3zp08j3	storage	requests	None	count	2.5033	value_nulo
evt_011a3k5yas7h	org_ir4cowgz	database	requests	None	count	5.5933	value_nulo
evt_01gzvk108sad	org_874frhoc	database	storage_gb_hours	None	gb_hours	0.9869	value_nulo

costo_negativo · los 3 más negativos (flag, no quarantine)

event_id	org_id	service	metric	value_raw	unit	cost_usd	quality_flags
evt_t5brta67j5l3	org_0lvsnujz	analytics	requests	121.0	count	-154.4608	costo_negativo
evt_9ur456xoexl5	org_h2m5zja8	genai	requests	140.0	count	-19.8245	costo_negativo
evt_zdg3w43spvdt	org_rixa11dp	genai	requests	122.0	count	-16.147	costo_negativo

B.2 Bronze, demostración con filas sucias

El dataset real no tiene rechazos en Bronze. Se agregan filas sucias conocidas a una copia temporal de Landing y se corre la misma ingesta; Landing real no se modifica.

customers_orgs.csv · 3 filas agregadas, 3 en quarantine, 80 en Bronze

regla	raw_record	record_json
clave_duplicada	None	{"org_id":"org_xaji0y6d","org_name":"Duplicada","industry":"Media","hq_region":"us-east","…
clave_nula	None	{"org_name":"Sin Clave","industry":"Media","hq_region":"us-east","plan_tier":"pro","is_ent…
no_parseable	org_demo_1,Fecha Rota,Media,us-east,pro,True,2025-13-45,rep_a,active,organic,10.0	{"org_id":"org_demo_1","org_name":"Fecha Rota","industry":"Media","hq_region":"us-east","p…

usage_events_stream · 4 líneas: 1 válida a Bronze, 3 en quarantine

regla	raw_record	record_json
event_id_nulo	None	{"timestamp":"2025-08-01T10:00:00Z","org_id":"org_xaji0y6d","resource_id":"res_x","service…
no_parseable	{"event_id": "evt_demo_roto", "timestamp":	{}
timestamp_invalido	None	{"event_id":"evt_demo_ts","timestamp":"ayer","org_id":"org_xaji0y6d","resource_id":"res_x"…

Anexo C · Serving en AstraDB

Keyspace `cloud_analytics` en AstraDB Serverless (AWS us-east-2). Tablas creadas por `load_cassandra` desde `infra/cql/schema.cql`:

```
CREATE TABLE IF NOT EXISTS org_daily_usage_by_service (
    org_id               text,
    usage_date           date,
    service              text,
    org_name             text,
    plan_tier            text,
    daily_cost_usd       double,
    daily_cost_gross_usd double,
    credit_adjustment_usd double,
    requests             double,
    cpu_hours            double,
    storage_gb_hours     double,
    genai_tokens         bigint,
    carbon_kg            double,
    event_count          bigint,
    source               text,        -- 'streaming' (provisorio) | 'reconciliacion'
    last_reconciled_at   timestamp,
    loaded_at            timestamp,
    PRIMARY KEY ((org_id), usage_date, service)
) WITH CLUSTERING ORDER BY (usage_date DESC, service ASC);
CREATE TABLE IF NOT EXISTS top_services_by_org_14d (
    org_id          text,
    as_of_date      date,
    rank            int,
    service         text,
    cost_14d_usd    double,
    requests_14d    double,
    days_with_usage int,
    window_start    date,
    loaded_at       timestamp,
    PRIMARY KEY ((org_id, as_of_date), rank)
) WITH CLUSTERING ORDER BY (rank ASC);
```

C.1 Justificación query-first

- **P1** filtra siempre por una organización y un rango de fechas: `org_id` es la partición y `usage_date` la primera clustering key, en orden descendente. El rango es un corte contiguo; 360 filas por organización.
- **P2** pide el Top-N de una organización a una fecha: la partición `(org_id, as_of_date)` tiene a lo sumo 6 filas, ordenadas por `rank`. Recalcular pisa la misma fila, porque el costo no forma parte de la clave.
- Ninguna consulta usa `ALLOW FILTERING` ni índices secundarios: lo verifica `tests/test_serving.py`.

C.2 Consultas y resultados

Q1 (P1) · costos y requests diarios de `org_okep7y6w` entre el 01/08 y el 07/08 · 25 filas, 39 ms:

```
SELECT usage_date, service, daily_cost_usd, requests, event_count, source
FROM cloud_analytics.org_daily_usage_by_service
WHERE org_id = 'org_okep7y6w'
  AND usage_date >= '2025-08-01' AND usage_date <= '2025-08-07';
```

usage_date	service	daily_cost_usd	requests	event_count	source
2025-08-07	compute	191.8968	212.0	3	reconciliacion
2025-08-07	networking	3.8985	378.0	6	reconciliacion
2025-08-07	storage	8.2649	345.0	9	reconciliacion
2025-08-06	compute	11.8077	121.0	3	reconciliacion
2025-08-06	database	6.0661	129.0	3	reconciliacion
2025-08-06	genai	10.6357	111.0	3	reconciliacion
2025-08-06	networking	0.3809	0.0	3	reconciliacion
2025-08-06	storage	2.8427	0.0	3	reconciliacion

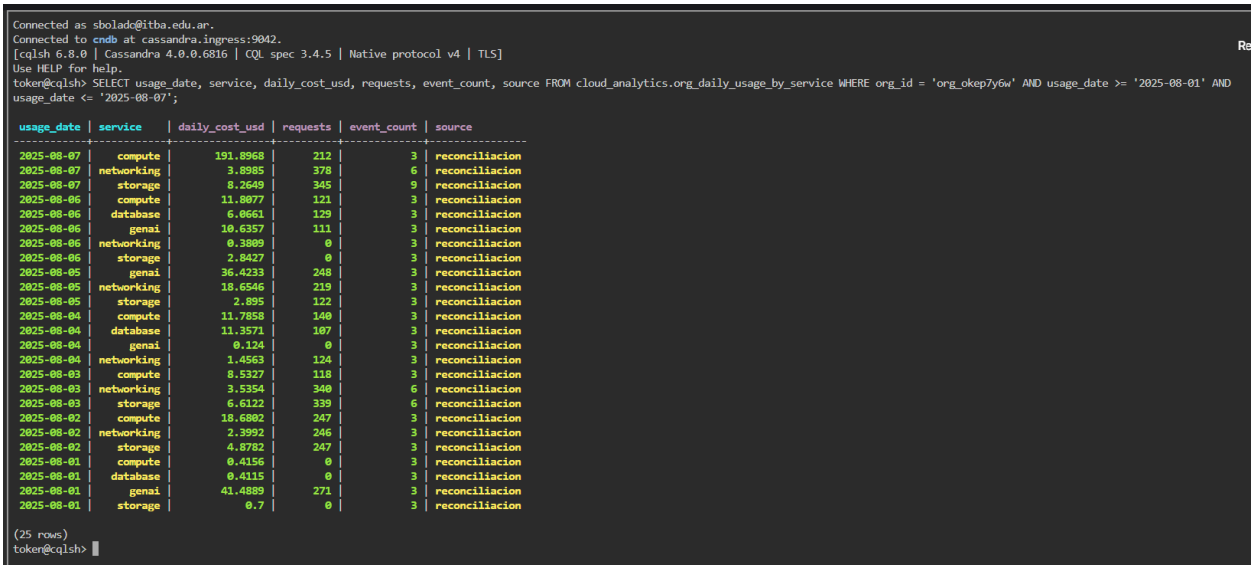
usage_date	service	daily_cost_usd	requests	event_count	source
2025-08-05	genai	36.4233	248.0	3	reconciliacion
2025-08-05	networking	18.6546	219.0	3	reconciliacion
2025-08-05	storage	2.895	122.0	3	reconciliacion
2025-08-04	compute	11.7858	140.0	3	reconciliacion
2025-08-04	database	11.3571	107.0	3	reconciliacion
2025-08-04	genai	0.124	0.0	3	reconciliacion
2025-08-04	networking	1.4563	124.0	3	reconciliacion
2025-08-03	compute	8.5327	118.0	3	reconciliacion
2025-08-03	networking	3.5354	340.0	6	reconciliacion
2025-08-03	storage	6.6122	339.0	6	reconciliacion
2025-08-02	compute	18.6802	247.0	3	reconciliacion
2025-08-02	networking	2.3992	246.0	3	reconciliacion
2025-08-02	storage	4.8782	247.0	3	reconciliacion
2025-08-01	compute	0.4156	0.0	3	reconciliacion
2025-08-01	database	0.4115	0.0	3	reconciliacion
2025-08-01	genai	41.4889	271.0	3	reconciliacion
2025-08-01	storage	0.7	0.0	3	reconciliacion

Q2 (P2) · Top-3 servicios por costo en los 14 días previos al 31/08 · 3 filas, 38 ms:

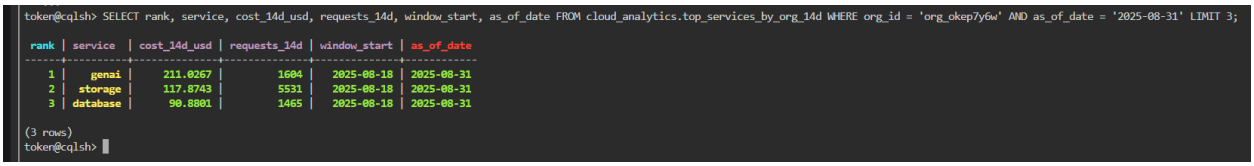
```
SELECT rank, service, cost_14d_usd, requests_14d, window_start, as_of_date
FROM cloud_analytics.top_services_by_org_14d
WHERE org_id = 'org_okep7y6w' AND as_of_date = '2025-08-31'
LIMIT 3;
```

rank	service	cost_14d_usd	requests_14d	window_start	as_of_date
1	genai	211.0267	1604.0	2025-08-18	2025-08-31
2	storage	117.8743	5531.0	2025-08-18	2025-08-31
3	database	90.8801	1465.0	2025-08-18	2025-08-31

C.3 Capturas de la CQL Console de AstraDB



Q1 ejecutada en la CQL Console (25 filas). evidence/serving/q1_cql_console.png



Q2 ejecutada en la CQL Console (3 filas). evidence/serving/q2_cql_console.png

---

Anexo D · Diccionario de datos y linaje

Resumen por dataset; las 292 columnas con tipo y descripción están en `docs/diccionario_datos.md`, generado desde `src/governance/catalog.py`.

Dataset	Zona	Grano	Partición	Resp.
bronze.customers_orgs	Bronze	el de la fuente	ingest_date	R2
quarantine.customers_orgs	Quarantine	un registro rechazado	ingest_date, regla	R2
bronze.users	Bronze	el de la fuente	ingest_date	R2
quarantine.users	Quarantine	un registro rechazado	ingest_date, regla	R2
bronze.resources	Bronze	el de la fuente	ingest_date	R2
quarantine.resources	Quarantine	un registro rechazado	ingest_date, regla	R2
bronze.support_tickets	Bronze	el de la fuente	ingest_date	R2
quarantine.support_tickets	Quarantine	un registro rechazado	ingest_date, regla	R2
bronze.marketing_touches	Bronze	el de la fuente	ingest_date	R2
quarantine.marketing_touches	Quarantine	un registro rechazado	ingest_date, regla	R2
bronze.nps_surveys	Bronze	el de la fuente	ingest_date	R2
quarantine.nps_surveys	Quarantine	un registro rechazado	ingest_date, regla	R2
bronze.billing_monthly	Bronze	el de la fuente	ingest_date	R2
quarantine.billing_monthly	Quarantine	un registro rechazado	ingest_date, regla	R2
bronze.usage_events	Bronze	un evento	ingest_date	R2
quarantine.usage_events	Quarantine	un evento rechazado	ingest_date, regla	R2
silver.customers_orgs	Silver	una organización	sin particionar	R3
silver.resources	Silver	un recurso	sin particionar	R3
silver.usage_events	Silver	un evento	event_date, service	R3
quarantine.silver_usage_events	Quarantine	una regla violada por un evento	regla	R2
gold.org_daily_usage_by_service	Gold	org_id, usage_date, service	usage_date	R3
gold.org_daily_usage_by_service_speed	Gold	clave del mart × micro-lote	batch_id	R3
gold.cost_anomaly_mart	Gold	org_id, date, service	date	R3
cassandra.org_daily_usage_by_service	Serving	org_id, usage_date, service	PK ((org_id), usage_date, service)	R4
cassandra.top_services_by_org_14d	Serving	org_id, as_of_date, rank	PK ((org_id, as_of_date), rank)	R4

Columnas del mart `gold.org_daily_usage_by_service`:

Columna	Tipo	Descripción
`org_id`	string	Identificador de la organización cliente (FK a customers_orgs).
`usage_date`	date	Día de uso; clave de partición de Gold.
`service`	string	Servicio cloud: compute, storage, database, networking, analytics, genai.
`daily_cost_usd`	double	Costo neto del día en USD (incluye créditos).
`daily_cost_gross_usd`	double	Costo bruto del día en USD (solo positivos).
`credit_adjustment_usd`	double	Suma de créditos del día en USD (negativo o cero).
`requests`	double	Feature: cantidad de requests.
`cpu_hours`	double	Feature: horas de CPU.
`storage_gb_hours`	double	Feature: GB-hora de almacenamiento.
`genai_tokens`	bigint	Tokens GenAI; solo v2 y service = genai.

Columna	Tipo	Descripción
carbon_kg	double	Huella de carbono en kg; solo eventos v2, nulo = no medido.
event_count	bigint	Cantidad de eventos agregados.
events_metric_null	bigint	Eventos con métrica nula cuyo costo sí se agregó (D-009).
org_name	string	Nombre de la organización.
plan_tier	string	Plan contratado: free, standard, pro o enterprise.
source	string	Ruta que produjo el valor: streaming (provisorio) o reconciliacion.
last_reconciled_at	timestamp	Fecha-hora de la última reconciliación del mart (§6.7).

D.1 Trazado de linaje de una anomalía

Generado con `notebooks/05_trazado_linaje.py`. Sigue la celda `org_okep7y6w · 2025-08-07 · compute` usando solo columnas de linaje del pipeline.

1. Gold · cost_anomaly_mart

org_id	date	service	daily_cost_gross_usd	baseline_median_usd	anomaly_score	is_anomaly
org_okep7y6w	2025-08-07	compute	191.8968	11.1426	44.374	True

2. Gold · org_daily_usage_by_service (el mart del que sale la anomalía)

org_id	usage_date	service	daily_cost_usd	event_count	source	last_reconciled_at
org_okep7y6w	2025-08-07	compute	191.8968	3	reconciliacion	2026-11-13 18:56:36

3. Silver · usage_events: los 3 eventos que suman USD 191.8968

event_id	event_ts	metric	value_num	cost_usd	quality_flags
evt_zjql5eyfdsd7	2025-08-07 01:33:00	cpu_hours	4.2643	0.4772	[]
evt_jdl0otbr13dk	2025-08-07 08:36:00	requests	101.0	182.2575	[]
evt_2i7k0o0k8098	2025-08-07 12:39:00	requests	111.0	9.1621	[]

4. Bronze · usage_events: cuándo y desde qué archivo llegó cada evento

event_id	value	cost_usd_increment	ingest_date	ingest_ts	source_file
evt_zjql5eyfdsd7	4.2643	0.4772	2026-11-13	2026-11-13 18:52:59.859000	events_part_0110.jsonl
evt_jdl0otbr13dk	101.0	182.2575	2026-11-13	2026-11-13 18:53:01.681000	events_part_0109.jsonl
evt_2i7k0o0k8098	111.0	9.1621	2026-11-13	2026-11-13 18:52:15.759000	events_part_0061.jsonl

5. Landing: la línea exacta en el archivo original

event_id	archivo	línea	contenido (inicio)…
evt_zjql5eyfdsd7	events_part_0110.jsonl	206	{"event_id": "evt_zjql5eyfdsd7", "timestamp": "2025-08-07T01:33:00Z",…
evt_jdl0otbr13dk	events_part_0109.jsonl	48	{"event_id": "evt_jdl0otbr13dk", "timestamp": "2025-08-07T08:36:00Z",…
evt_2i7k0o0k8098	events_part_0061.jsonl	93	{"event_id": "evt_2i7k0o0k8098", "timestamp": "2025-08-07T12:39:00Z",…

La anomalía la explica `evt_jdl0otbr13dk` (USD 182,26). Los tres eventos de la celda llegaron en tres archivos distintos: la fragmentación aleatoria de A-07 en un caso concreto.

Anexo E · Backlog final

Priorizado según la consigna (§6.2, §6.6). Regla de congelamiento: lo deseable se empieza solo con lo obligatorio del mismo eje terminado, y nada deseable después del 30/11.

Obligatorio (80 horas-persona):

#	Ítem	Requisito	Resp.	h	Evidencia de cierre
O-1	Mart `revenue_by_org_month` (P4): Silver de billing con FX = 1,0 en USD y `credits` nulo = 0 (D-007), Gold mensual	§7.3, consulta 4	R3	8	Revenue total y por factura contra un cálculo independiente
O-2	Mart `tickets_by_org_date` (P3): conteos por severidad, tasa de incumplimiento de SLA, CSAT promedio; nulos semánticos sin quarantine	§7.3, consulta 3	R3	6	Totales cuadran con Bronze (1.000 tickets, 95 SLA, 56 críticos)
O-3	Mart `genai_tokens_by_org_date` (P5): tokens y costo estimado; solo v2 y genai	§7.3, consulta 5	R3	4	Tokens totales = suma en Silver
O-4	Tablas query-first y consultas Q3, Q4 y Q5 en AstraDB, con CQL, justificación y captura	§7.4	R4	8	`evidence/serving/` con las 5 consultas, < 1 s cada una
O-5	Invariantes entre columnas del TP1 (§9.7): `last_login >= created_at` (232) y `converted` ⇒ `clicked` (96) como flags en Silver de `users` y `marketing_touches`	§7.2 punto 7; coherencia con el diseño	R2	3	Conteos iguales a los del perfilado
O-6	Cerrar A-09: el componente analítico es `cost_anomaly_mart`, con métricas y límites (D-016). P7 pasa a deseable	§7.2 punto 6	R3	2	Decisión registrada; sección en la documentación
O-7	Extender gobierno a los marts nuevos: catálogo, diccionario, controles de conservación, tests e idempotencia	§7.2 puntos 7 y 8	R1 / R2	5	`test_governance` en verde; doble corrida con variación 0
O-8	Notebook de Colab y `src.pipeline` con los 5 marts y las 5 consultas, validados desde entorno limpio	§7.2 punto 10, O7	R4	4	Corrida limpia en Colab con evidencias
O-9	Diagrama v3 final y documentación técnica: arquitectura, modelo de serving, calidad, gobierno, linaje y limitaciones	§7.5	R1	10	`docs/` consistente con el código
O-10	Incorporar el feedback de la 2.ª entrega (16/11) como plan de correcciones	§6.6	R1	4	`docs/plan_correcciones.md` actualizado
O-11	Presentación ejecutiva	§7.5	los 4	10	Deck
O-12	Video explicativo: pipeline, resultados y consultas	§7.5	los 4	8	Video
O-13	Defensa: guion, demo y plan B si AstraDB falla (evidencias y capturas, riesgo G-02)	§7.2 punto 10, §8.4	los 4	8	Ensayo con tiempo medido
	Subtotal obligatorio			**80**	

Deseable (25 horas-persona):

#	Ítem	Valor	Resp.	h
D-1	Token de AstraDB de solo lectura para el consumo (mínimo privilegio)	Seguridad, declarado en `docs/gobierno.md`	R4	1
D-2	`cost_anomaly_mart` en AstraDB (P6)	Serving de las anomalías	R4	3
D-3	MAD con ventana móvil en lugar de la serie completa	Detección más realista en producción (D-016)	R3	4
D-4	Reconciliación incremental: recomputar solo las fechas que tocaron los lotes nuevos	Escala (D-005, §12.6 del TP1)	R3	5
D-5	P7: relación entre experiencia de soporte y riesgo de abandono	Pregunta del TP1, con señal débil: 20 orgs sin NPS, 25% de tickets sin CSAT	R3	8
D-6	SCD tipo 2 para `customers_orgs`	Historia de cambios de plan y etapa	R3	4
	Subtotal deseable			**25**

Fuera de alcance:

Ítem	Motivo
Orquestación con Airflow	`src.pipeline` alcanza para la demo; la cadencia es manual
Lakehouse (Delta o Iceberg)	Resolvería upserts y time travel, pero cambia el formato pedido (Parquet)
Clúster real (YARN, Kubernetes) y almacenamiento de objetos	El entorno es Colab `local[*]` (S-01)
Herramienta de visualización propia	El serving se expone para un BI externo

Ítem	Motivo
Anomalías con estacionalidad	4 meses de datos no alcanzan para calibrarla
Ejecución de la retención por zona	Declarada; no se puede ejercitar con 4 meses
Conector JVM de Spark para Cassandra	El driver de Python cubre el caso (D-017)

Calendario:

Semana	Foco
17–23/11	O-10, O-1, O-2, O-3, O-5
24–30/11	O-4, O-6, O-7, O-8 · deseables D-1 a D-3 si sobra tiempo · **30/11: congelamiento**
01–07/12	O-9, O-11, O-12, O-13 · ensayo de la defensa · entrega el 07/12 a las 21:30